



Лекция 2

...

ExpressML

Повторение: нейрон




Повторение: Функция активации, сигмоида

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

$$\sigma(-\infty) = 0$$

$$\sigma(+\infty) = 1$$

$$\sigma(x)' = \sigma(x)(1 - \sigma(x))$$



Повторение: BCE + сигмоида

Binary

Cross-Entropy

$$BCE(\vec{x}, y) = -[(1-y) \log(1-p) + y \log p] \quad p = \sigma(z)$$

$$\frac{\partial}{\partial z} BCE = \sigma(z) - y$$

Повторение: функции ошибки, откуда берутся

$BCE(\vec{x}, y)$ - Бернулли

$$P = C_N^n \cdot p^n \cdot (1-p)^{N-n}$$

N раз
 n раз $- + \text{исход} (p)$

$MSE(x)$ - Норм. Распр.

Повторение: SoftMax

$$\text{SoftMax}(x) = \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}} > 0$$

$$\sum_{i=1}^N \text{SoftMax} = 1$$

$$\sum_{i=1}^N \frac{e^{x_i}}{\left[\sum_{j=1}^N e^{x_j} \right]} = \frac{\sum_{i=1}^N e^{x_i}}{\sum_{j=1}^N e^{x_j}} = 1$$

$$\left[\frac{\partial}{\partial x_k} \text{SoftMax} \right] = \frac{\partial}{\partial x_k} \frac{e^{x_i}}{\sum_{j=1}^N e^{x_j}}$$

1) $k=i$ $\frac{e^{x_i} \cdot \sum_{j=1}^N e^{x_j} - e^{x_i} \cdot e^{x_i}}{\left(\sum_{j=1}^N e^{x_j} \right)^2} = \frac{e^{x_i} \left(\sum_{j=1}^N e^{x_j} - e^{x_i} \right)}{\left(\sum_{j=1}^N e^{x_j} \right)^2}$

2) $k \neq i$ $\frac{\partial \left(\sum_{j=1}^N e^{x_j} \right)}{\partial x_k}$

$$e^{x_1} + e^{x_2} + \dots + \boxed{e^{x_k}} + \dots + e^{x_N}$$

$$\frac{0 - e^{x_i} \cdot e^{x_k}}{\left(\sum_{j=1}^N e^{x_j} \right)^2}$$

$$\text{SoftMax} (1 - \text{SoftMax})$$


$$1) \frac{e^{x_i} - e^{x_i} e^{x_k}}{\left(\sum_{j=1}^N e^{x_j}\right)^2} = \text{SoftMax}_i - \text{SoftMax}_i \text{SoftMax}_k$$

$$2) \frac{0 - e^{x_i} e^{x_k}}{\left(\sum_{j=1}^N e^{x_j}\right)^2} = 0 - \text{SoftMax}_i \text{SoftMax}_k$$

$$\text{SoftMax}_i \delta_{ik} - \text{SoftMax}_i \text{SoftMax}_k = \text{SoftMax}_i (\delta_{ik} - \text{SoftMax}_k)$$

$$\delta_{ik} = \begin{cases} 0 & i \neq k \\ 1 & i = k \end{cases}$$

SoftMax + CE (\vec{x}, \vec{y})

$$(\vec{x}, \vec{y})$$


Cross Entropy = -



$$L = BCE = \underbrace{\left[-y \log p \right]}_{\substack{\text{if } y=0.8}} - \underbrace{\left[(1-y) \log (1-p) \right]}_{\substack{\text{if } y=0.8}}$$



$$CE = \sum_{i=1}^N -y_i \cdot \log p_i$$

$$p_i = \text{SoftMax}(\frac{z}{2});$$


$$\frac{\partial}{\partial \mathbf{z}_k} CE = \sum_{i=1}^n -y_i \frac{\partial}{\partial \mathbf{z}_k} \log p_i =$$

$$= \sum_{i=1}^N -y_i \cdot \frac{1}{p_i} \cdot p_k (\delta_{ki} - p_i) = \sum_{i=1}^N -y_i \frac{p_k \delta_{ki}}{p_i}$$

$$\textcircled{2} \sum_{i=1}^N -y_i \frac{p_k \delta_{ki}}{p_i} + y_i \frac{1}{p_i} p_k \cdot p_i \Rightarrow \begin{cases} 1) k=i: -y_i + y_i p_i \\ 2) k \neq i: y_i p_i \end{cases}$$

Оптимизация Нейронных Сетей

Повторение: оптимизация, градиентный спуск



$x_0 \quad \mathcal{L}(x) \rightarrow \min$

$\nabla \mathcal{L}(x_0) \quad \underbrace{x_1 = x_0 - \nabla \mathcal{L}(x_0) \cdot \alpha}_{\text{скорость град спуска}}$

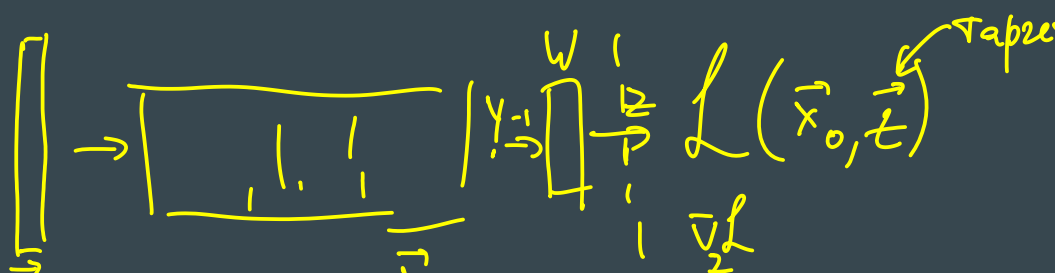
$x_2 = x_1 - \nabla \mathcal{L}(x_1) \cdot \alpha$

конечные разности

$\mathcal{L}(x_0) \quad x_0^i = x_0^i + \Delta x$

$$\frac{\partial \mathcal{L}}{\partial x^i} \approx \frac{\mathcal{L}(x_0^i + \Delta x) - \mathcal{L}(x_0^i)}{\Delta x}$$

Обратное распространение ошибки и Chain Rule



t - таргет
 y - выход из акт
 z - выход из Σ
 W - веса
 b - bias

$$L = L(\vec{t}, \sigma(\vec{z})) = L(\vec{y}, \sigma(W \cdot y_{-1})) =$$

$$y_{-1} = \text{act}_{-1}(z_{-1})$$

$$z_{-1} = W_{-1} \cdot y_{-2} + b_{-2}$$

$$\frac{\partial f(g(x))}{\partial x} = \frac{\partial g}{\partial x} \cdot \frac{\partial f}{\partial g}$$

$$\frac{\partial f(g(e(x)))}{\partial x} = \frac{\partial e}{\partial x} \cdot \frac{\partial g}{\partial e} \cdot \frac{\partial f}{\partial g}$$

φ-а нотарь
2раф



$$\left(\frac{\partial f}{\partial g} \cdot \frac{\partial g}{\partial e} \cdot \frac{\partial e}{\partial x} \right)$$

$$\frac{\partial \mathcal{L}}{\partial \text{param}_e} = \frac{\partial f}{\partial g} \cdot \frac{\partial g}{\partial e} \cdot \frac{\partial e}{\partial \text{param}_e}$$


param.
↑

$$\frac{\partial \mathcal{L}}{\partial \text{param}_g} = \frac{\partial f}{\partial g} \cdot \frac{\partial g}{\partial \text{param}_g}$$

$g(e(x), \text{param})$

$$\frac{\partial f}{\partial \text{param}_f}$$

Градиентный спуск и Chain Rule





$$\vec{State}_1 = \vec{State}_0 - \alpha \nabla L(\vec{State}_0)$$

$$\vec{State}_2 = \vec{State}_1 - \alpha \nabla L(\vec{State}_1)$$



\vdots

Проблемы градиентного спуска: проблема 1



Nesterov Momentum

Nesterov Momentum (иллюстрация)



Проблема 2: Усреднение множества градиентов

Батчи

Adam

Rprop

Вопросы по оптимизации

Некоторые проблемы

Проблема инициализации весов

Инициализация Ксавьера

Проблема Затухания градиента

ReLU, ELU

Проблема переобучения

Регуляризация (Weight Decay)

Drop-Out

Нормализация и центровка данных

Batch Normalization

